МИНОБРНАУКИ РОССИИ
федеральное государственное бюджетное образовательное учреждение высшего образования
«Национальный исследовательский университет «МЭИ»

Институт информационных и вычислительных технологий

Кафедра управления и интеллектуальных технологий

Отчет по лабораторной работе №1
По курсу «Интеллектуальный анализ данных»
«Построение и анализ регрессионных зависимостей»

Выполнили студенты: Михайловский Михаил, Озеров Сергей

Группа: А-03-21

Проверил: Назаров Николай Алексеевич

Москва 2023

Датасет ирисы Фишера

Подготовка датасета

Импортируем датасет с ирисами из *skrlearn.datasets*. Столбцы *sl*, *sw*, *pl*, *pw* - это некоторые параметры различных ирисов, а *target* - это тип ириса.

In [ ]:
```
from sklearn.datasets import load_iris
import numpy  as np
import pandas as pd

iris = load_iris()
iris_pd=pd.DataFrame(data=np.c_[iris['data'], iris['target']], columns=iris['fea
iris_pd = iris_pd.rename(columns={'sepal length (cm)': 'sl', 'sepal width (cm)':

print(iris_pd)
print(iris_pd.describe())
```

```
      sl   sw   pl   pw  target
0    5.1  3.5  1.4  0.2     0.0
1    4.9  3.0  1.4  0.2     0.0
2    4.7  3.2  1.3  0.2     0.0
3    4.6  3.1  1.5  0.2     0.0
4    5.0  3.6  1.4  0.2     0.0
..   ...  ...  ...  ...     ...
145  6.7  3.0  5.2  2.3     2.0
146  6.3  2.5  5.0  1.9     2.0
147  6.5  3.0  5.2  2.0     2.0
148  6.2  3.4  5.4  2.3     2.0
149  5.9  3.0  5.1  1.8     2.0

[150 rows x 5 columns]
               sl          sw          pl          pw      target
count  150.000000  150.000000  150.000000  150.000000  150.000000
mean     5.843333    3.057333    3.758000    1.199333    1.000000
std      0.828066    0.435866    1.765298    0.762238    0.819232
min      4.300000    2.000000    1.000000    0.100000    0.000000
25%      5.100000    2.800000    1.600000    0.300000    0.000000
50%      5.800000    3.000000    4.350000    1.300000    1.000000
75%      6.400000    3.300000    5.100000    1.800000    2.000000
max      7.900000    4.400000    6.900000    2.500000    2.000000
```

1. Разведочный анализ данных

Построить диаграмму Тьюки, оценить диапазон изменения данных.

In [ ]:
```
import matplotlib.pyplot as plt

iris_pd.iloc[:,:-1].boxplot()
plt.title('Диаграммы тьюки для параметров цветков')
plt.show()
```

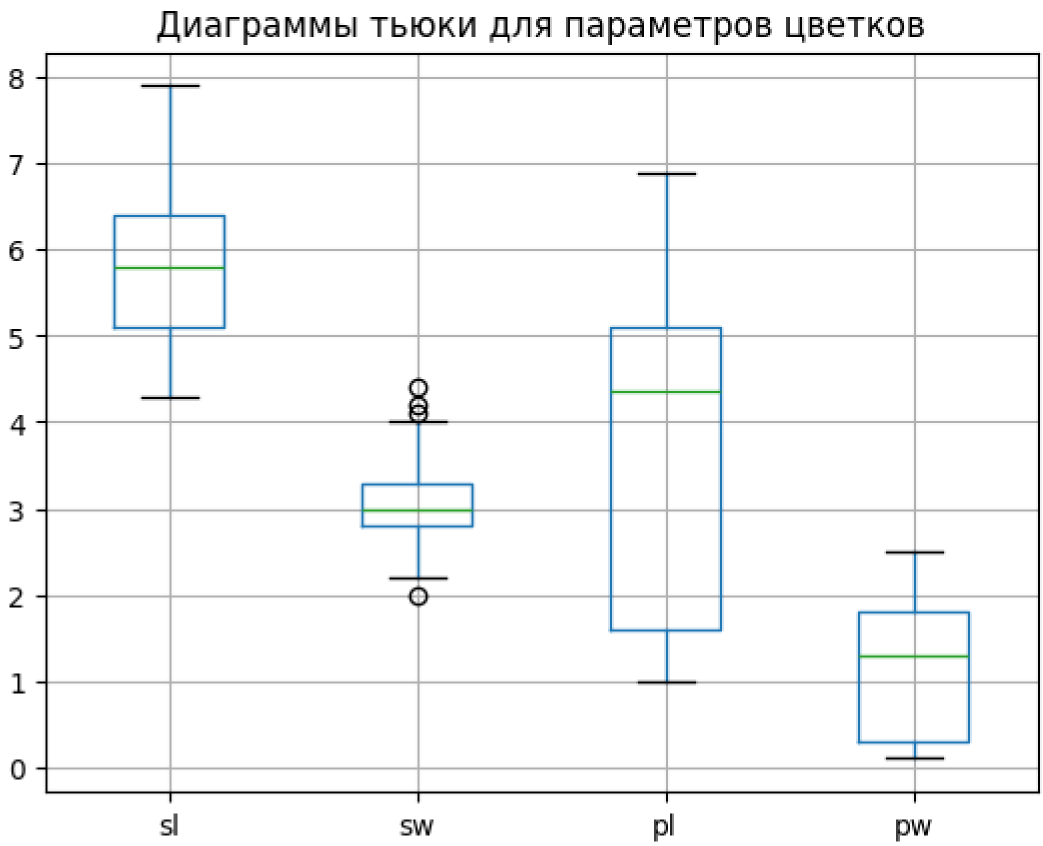

Значения всех переменных сравнимы по величине, но находятся в нескольких разных диапазонах и имеют разный разброс. Также стоит отметить, что для значений sw имеем большое количество выбросов.

Проанализировать корреляционные зависимости между исследуемыми переменными. Необходимо построить тепловую карту.

Парная корреляция между i и j переменными можно найти по следующей формуле:

$$\hat{r}_{ik} = \frac{\hat{\sigma}_{ik}}{\hat{\sigma}_{ii}\hat{\sigma}_{kk}}$$

In [ ]:
```
import seaborn as sns

corr_matr = iris_pd.corr()
print(corr_matr)

sns.heatmap(corr_matr, annot= True, vmin=-1, vmax=1)
plt.title('Тепловая карта парных корреляций')
plt.show()
```

```
              sl        sw        pl        pw    target
sl      1.000000 -0.117570  0.871754  0.817941  0.782561
sw     -0.117570  1.000000 -0.428440 -0.366126 -0.426658
pl      0.871754 -0.428440  1.000000  0.962865  0.949035
pw      0.817941 -0.366126  0.962865  1.000000  0.956547
target  0.782561 -0.426658  0.949035  0.956547  1.000000
```

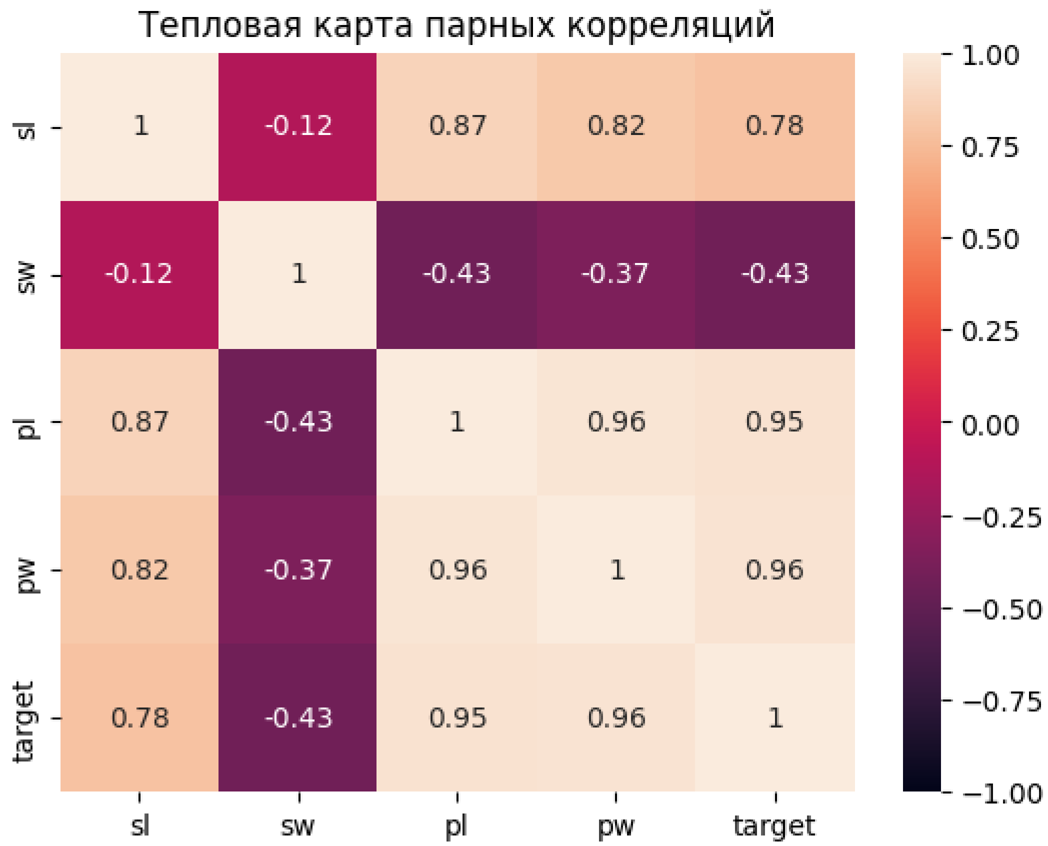

Практически все переменные имеют высокие линейные связи друг с другом, кроме пар содержащих sw. Еще можно обратить внимание, что парные корреляции отдельных переменных со всеми остальными имеют похожие значения.

Рассчитать частные коэффициенты корреляции, сравнить их со значениями парных коэффициентов корреляции. Необходимо построить тепловую карту.

Частная корреляция между i и j переменными можно найти по следующей формуле:

$$\hat{r}_{ik|1,...,L} = -\frac{\hat{R}_{ik}}{\sqrt{\hat{R}_{ii}\hat{R}_{kk}}}, \text{где } \hat{R}_{xy} \text{ -- алгебраическое дополнение корреляционной }$$

In [ ]:
```
import pingouin

pcorr_matr = iris_pd.pcorr()
print(pcorr_matr)

sns.heatmap(pcorr_matr, annot= True, vmin=-1, vmax=1)
plt.title('Тепловая карта частных корреляций')
plt.show()
```

```
              sl        sw        pl        pw    target
sl      1.000000  0.610735  0.723756 -0.220409 -0.159156
sw      0.610735  1.000000 -0.565057  0.336649 -0.055676
pl      0.723756 -0.565057  1.000000  0.578470  0.316796
pw     -0.220409  0.336649  0.578470  1.000000  0.472174
target -0.159156 -0.055676  0.316796  0.472174  1.000000
```

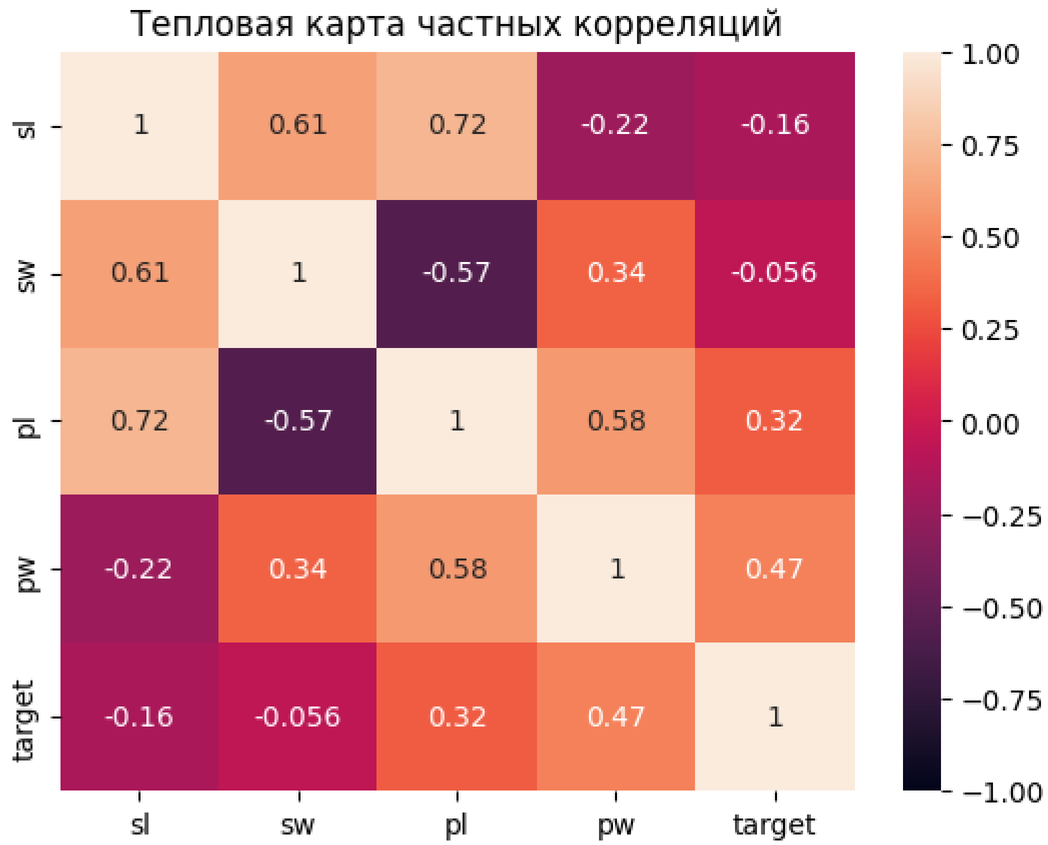

По сравнению с матрицей парных корреляций частные корреляции отдельных переменных со всеми остальными значительно различаются, в том числе могут менять знак. Можно отметить, что тип цветка, судя по значениям коэффициентов частной корреляции, в большей мере определяется параметрами *pl* и *pw*.

Расчитаем коэффициент множественной корреляции для target. Это можно сделать по следующей формуле:

$$\hat{R}_{y|x^{(1)}\ldots x^{(M-1)}} = \sqrt{1 - \frac{|\hat{R}|}{\hat{R}_{ii}}}$$

In [ ]:
```python
#Количество параметров
n = len(iris_pd)
k = len(iris_pd.iloc[0]) - 1

def minor(A, i, j):
    a_shape = A.shape[0]
    M = np.eye(a_shape - 1)
    M[:i,:j] = A[:i,:j]
    M[:i,j:] = A[:i,j+1:]
    M[i:,:j] = A[i+1:,:j]
    M[i:,j:] = A[i+1:,j+1:]

    return M
```

```python
def alg_dop(A, i, j):
    M = minor(A, i, j)
    return (-1)**(i+j) * np.linalg.det(M)

R = corr_matr.values
#Множественная корреляция y к x-ам
R_y_x = np.sqrt(1 - np.linalg.det(R)/alg_dop(R, k, k))
print(f'Коэффициент множественной корреляции target: {R_y_x:.3f}')
```

```
Коэффициент множественной корреляции target: 0.965
```

По большому значению коэффициента множественной корреляции, можно сказать, что тип цветка имеет сильную линейную связь с его параметрами.

Проверить предположение о распределении признаков по нормальному закону критерием Колмогорова-Смирнова. Необходимо рассчитать значения статистик.

In [ ]:
```python
import scipy.stats

kstest_res = [ scipy.stats.kstest(iris_pd.iloc[:,i], 'norm') for i in range(len(
for i in range(len(kstest_res)):
    print(f'Значение статистики для {iris_pd.columns[i]}: {kstest_res[i].statist
```

```
Значение статистики для sl: 1.000, pvalue: 0.00e+00
Значение статистики для sw: 0.979, pvalue: 1.93e-253
Значение статистики для pl: 0.877, pvalue: 1.40e-136
Значение статистики для pw: 0.546, pvalue: 1.88e-42
Значение статистики для target: 0.508, pvalue: 2.10e-36
```

По результатам критерия Колмогорова-Смирнова данные столбцы противоречат предположению о нормальности закона распределения данных величин, поскольку значение pvalue в каждой из них практически нулевое.

Сделать выводы о степени однородности данных, силе зависимости между переменными, виде функции распределения, наиболее информативных переменных.

In [ ]:
```python
iris_pd.iloc[:,:-1].hist(bins = 8, edgecolor='black')
plt.show()
```

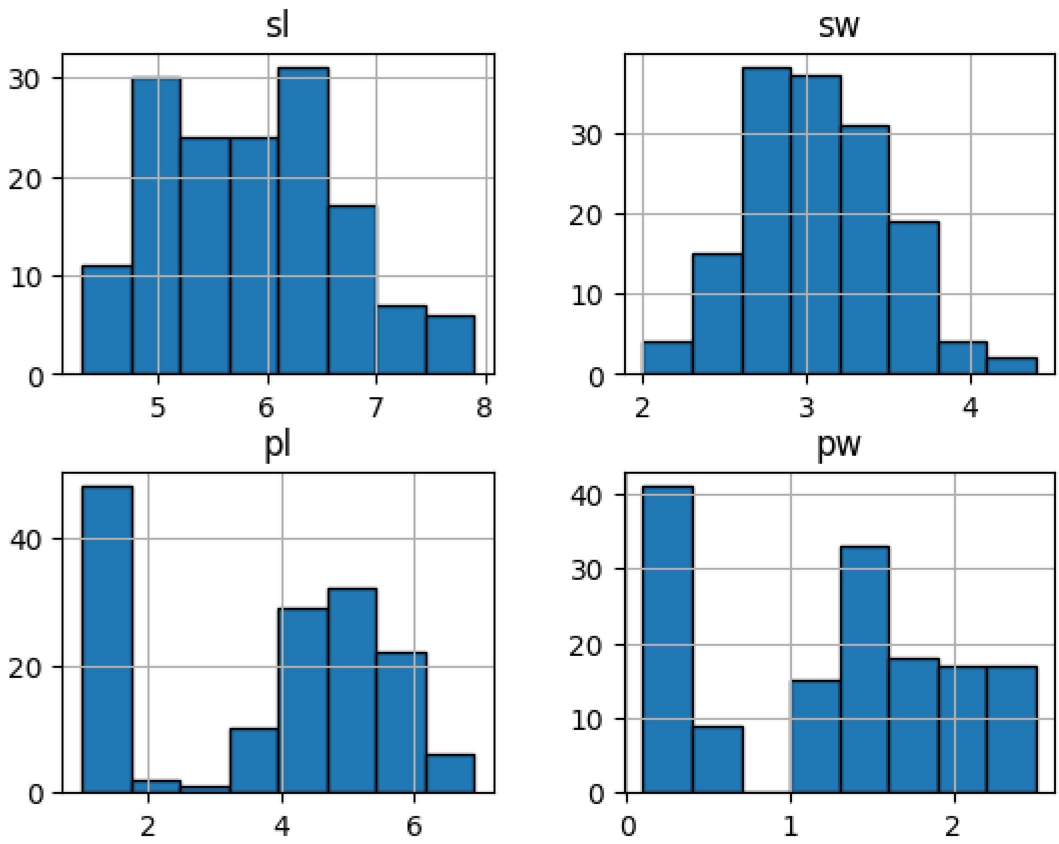

Построим гистограммы имеющихся данных. По ним видно, что оценки законов распределения данных выборок весьма различны и отличаются от нормального закона распределения, что подтвердил критерий Колмогорова-Смирнова. Заметим, что характер оценок дифференциального закона распределения для *pl* и *pw* визуально похож.

Судя по корреляционным коэффициентам, параметры ирисов имеют, как минимум, небольшую линейную связь. Есть связи как прямые так и обратные и их силы различны. Смотря на коэффициенты частной корреляции, можно предположить, что наиболее информативными для определения типа ириса являются параметры *pl* и *pw*, поскольку эти параметры имеют наибольшие оценки частной корреляции с типом цветка.

Построение регрессии

Определить входные и выходные переменные. Построить парную регрессию и множественную регрессию (Используем sklearn).

При построении парной линейной регрессии мы рассматриваем модель вида: $\hat{y} = \hat{b}_0 + \hat{b}_1 \cdot x$, где коэффициенты $\hat{b}_0, \ \hat{b}_1$ - это неизвестные, которые находятся по выборке. Модель множественной линейной регрессии имеет вид: $\hat{y} = \hat{b}_0 + \widehat{\vec{b}^T} \vec{x}$

Для оценки качества модели будем использовать коэффициенты детерминации и скорректированной детерминации:

$$R^2 = 1 - \frac{Q_{\text{ост}}}{Q_{\text{общ}}},\ R^2_{\text{корр}} = 1 - \frac{S^2_{\text{ост}}}{S^2_{\text{общ}}}$$

Здесь $Q_{\text{общ}} = \sum_{j=1}^{N}(y_j - \bar{y}_j)^2,\ Q_{\text{ост}} = \sum_{j=1}^{N}(\hat{y}_j - y_j)^2,\ S^2_{\text{общ}} = \frac{Q_{\text{общ}}}{N-1},\ S^2_{\text{ост}} = \frac{Q_{\text{ост}}}{N-k}$

В нашем наборе данных прикладной задачей было бы определение типа цветка ирисов по его параметрам. Поэтому, в качестве входных переменных, можно взять параметры цветков *sl*, *sw*, *pl*, *pw*, а выходной переменной выбрать тип цветка.

In [ ]:
```
from sklearn import linear_model
#Получение парной линейной регресси
def pair_regress(data_pd, x_name, y_name):
    x = data_pd[x_name].values.reshape(-1, 1)
    y = data_pd[y_name].values.reshape(-1, 1)

    reg = linear_model.LinearRegression()
    reg.fit(x,y)

    return reg

#Построить графики результатов регрессии
def plot_regr_results(x, y, y_pred):
    residues = y - y_pred
    plt.figure(figsize=(12.8,6))
    plt.subplot(1, 2, 1)
    plt.grid()
    plt.plot(x, y, 'ko', label='iris data')
    plt.plot(x, y_pred, label='Предсказание')
    plt.title(f'Парная регрессия по {column}')
    plt.xlabel(column)
    plt.ylabel('target')
    plt.legend()

    plt.subplot(1, 2, 2)
    plt.grid()
    plt.plot(x, y_pred, label='Предсказание')
    plt.plot(x, residues, 'r+', label='Остатки')
    plt.title('Остатки')
    plt.xlabel(column)
    plt.show()

#Получение коэффициентов детерминации и скорретированной детерминации
def calc_r_squared(y, y_pred, k, return_Q = False):
    res = []
    n = len(y)
    delta_y = (y - y.mean()).reshape(-1)
    residues = (y - y_pred).reshape(-1)
    Q = np.dot(delta_y, delta_y)
    S = Q / (n-1)
    Q_res = np.dot(residues, residues)
    S_res = Q_res / (n-k)
    res.append(1 - Q_res/Q)
    res.append(1 - S_res/S)
    if return_Q:
        res.append(Q)
        res.append(Q_res)
```

```
    return res

reg = dict()
for column in list(iris_pd.columns)[:-1]:
    reg[column] = pair_regress(iris_pd, column, 'target')

R_squared = dict()
R_adj_squared = dict()
Q = None
Q_res = dict()
RMSE = dict()
iris_y = iris_pd['target'].values.reshape(-1, 1)
delta_y = (iris_y - iris_y.mean()).reshape(-1)
for column in reg:
    iris_x = iris_pd[column].values.reshape(-1, 1)
    iris_y_pred = reg[column].predict(iris_x)
    plot_regr_results(iris_x, iris_y, iris_y_pred)

    R_sq, R_adj_sq, Q, Q_res[column] = calc_r_squared(iris_y, iris_y_pred, 1, re
    R_squared[column] = (R_sq)
    R_adj_squared[column] = (R_adj_sq)
    RMSE[column] = np.sqrt(((iris_y - iris_y_pred) ** 2).mean())

def print_num_dict(dic, round_to):
    for column, val in dic.items():
        print(f'{column}: {val:.{round_to}f}', end='\t')
    print()

print('Коэффициенты детерминации')
print_num_dict(R_squared, 3)
print('Коэффициенты скорректированной детерминации')
print_num_dict(R_adj_squared, 3)
print('Стандартная ошибка')
print_num_dict(RMSE, 3)
print(f'Q общее: {Q:.3f}')
print(f'Q остаточное')
print_num_dict(Q_res, 3)
```

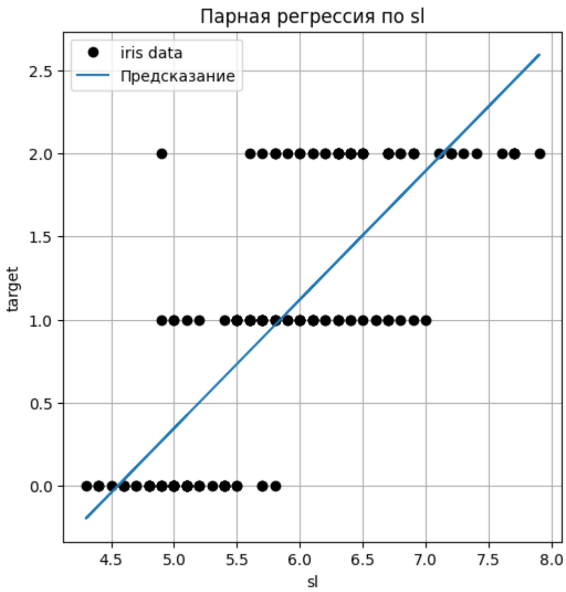

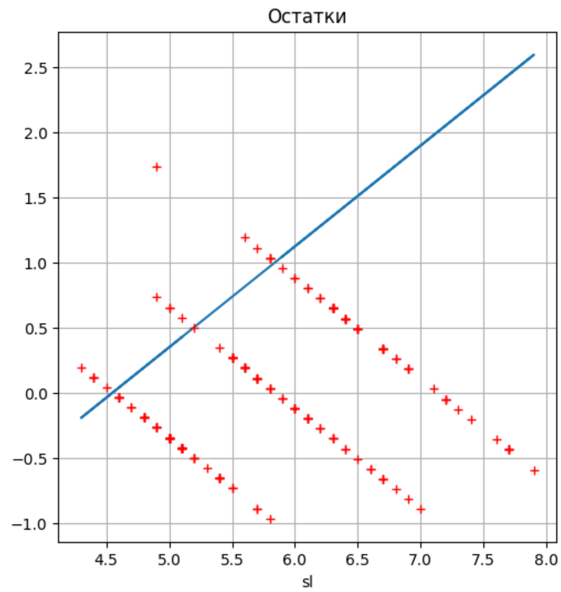

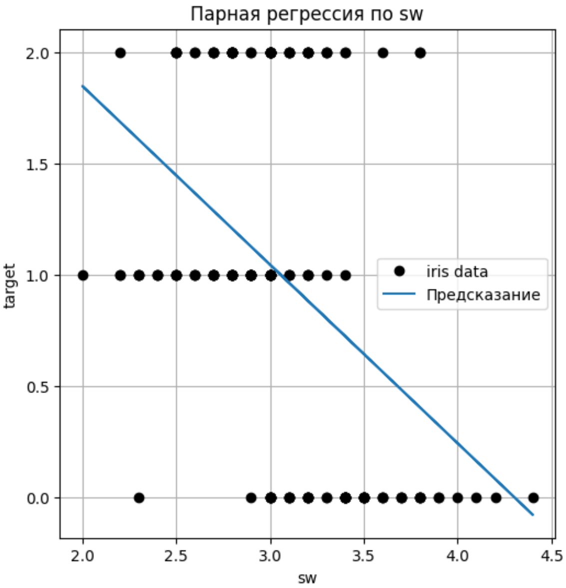
Парная регрессия по sw
target
sw
iris data
Предсказание
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5

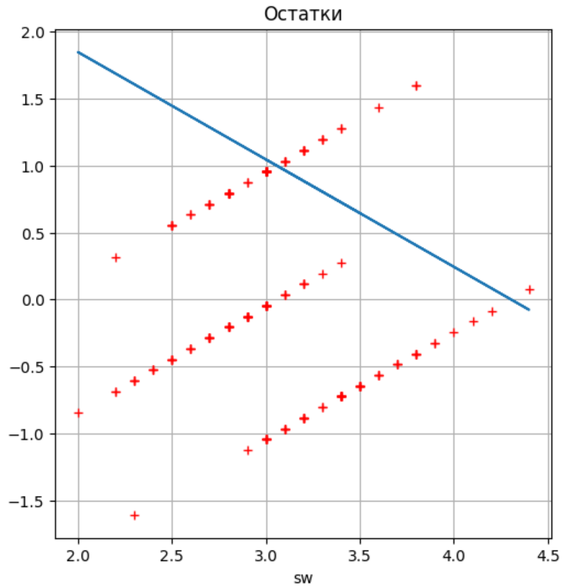
Остатки
sw
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0
4.5

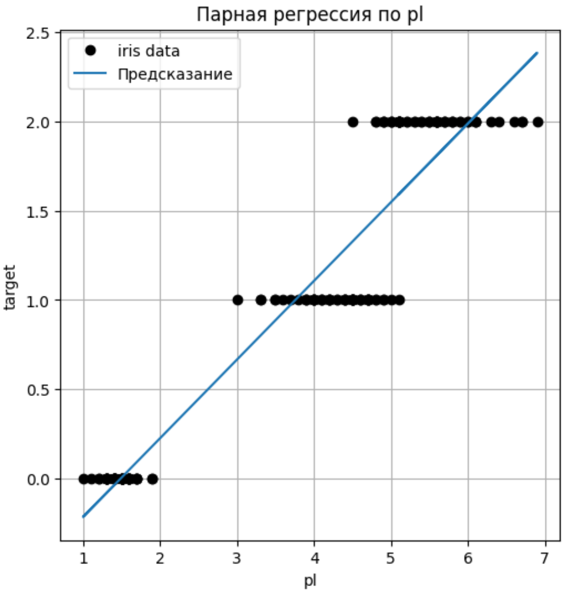
Парная регрессия по pl
target
pl
iris data
Предсказание
0.0
0.5
1.0
1.5
2.0
2.5
1
2
3
4
5
6
7

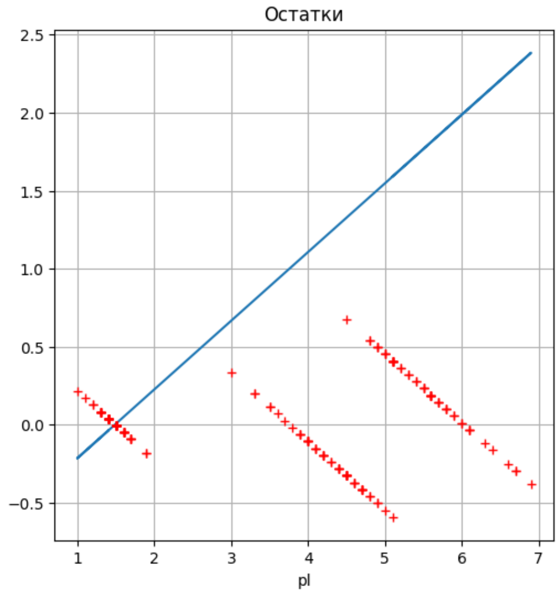
Остатки
pl
−0.5
0.0
0.5
1.0
1.5
2.0
2.5
1
2
3
4
5
6
7

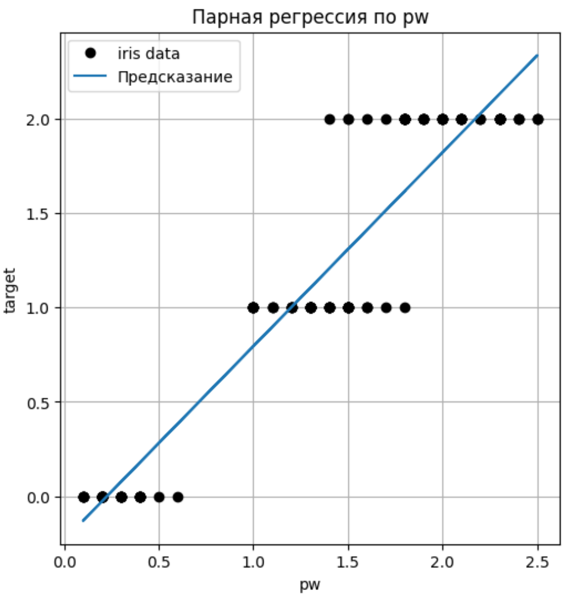
Парная регрессия по pw
target
pw
iris data
Предсказание
0.0
0.5
1.0
1.5
2.0
2.5

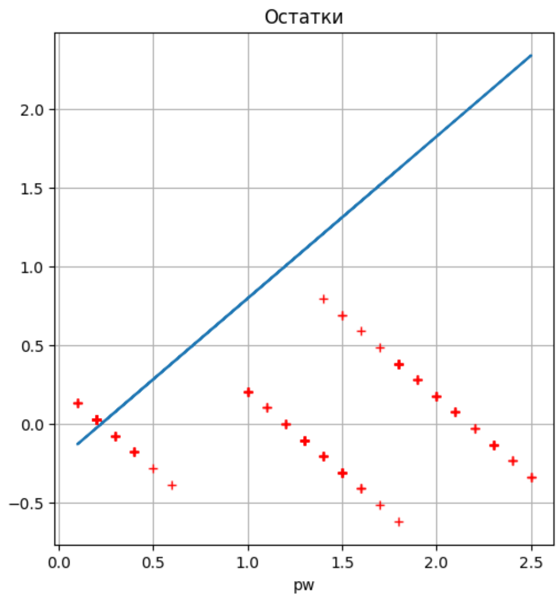
Остатки
pw
−0.5
0.0
0.5
1.0
1.5
2.0
2.5

```
Коэффициенты детерминации
sl: 0.612       sw: 0.182       pl: 0.901       pw: 0.915
Коэффициенты скорректированной детерминации
sl: 0.612       sw: 0.182       pl: 0.901       pw: 0.915
Стандартная ошибка
sl: 0.508       sw: 0.738       pl: 0.257       pw: 0.238
Q общее: 100.000
Q остаточное
sl: 38.760      sw: 81.796      pl: 9.933       pw: 8.502
```

Визуально полученные модели парных линейных регрессий подходят к данным и неплохо их оценивают. Модель построенная по второму параметру (*sw*) получилась некачественной, что видно и визуально, и по модулям значений остатков.

Смотря на коэффициенты детерминации, можно сказать, что модели построенные на первых двух параметрах хуже, чем модели на последних двух. В частности, вторая модель вовсе не пригодна, первая не очень хорошая, а последние две можно считать удачными.

Стоит отметить, что качество моделей получилось соответствующим порядку их рассчитанной корреляции со значением *target*.

Теперь построим модель множественной линейной регрессии.

In [ ]:

```
m_reg = linear_model.LinearRegression()
iris_m_x = iris_pd.iloc[:,:-1].values.reshape(-1, k)

m_reg.fit(iris_m_x, iris_y)
reg['multiple'] = m_reg
iris_m_y_pred = m_reg.predict(iris_m_x)
m_residues = (iris_y - iris_m_y_pred).reshape(-1)
Q_res['multiple'] = np.dot(m_residues, m_residues)

m_R_squared, m_R_adj_squared = calc_r_squared(iris_y, iris_m_y_pred, k)
m_SE = np.std(iris_m_y_pred, ddof=k) / np.sqrt(n)

print(f'Детерминация: {m_R_squared:.3f}\nСкорректированная детерминация: {m_R_ad
print(f'Стандартная ошибка: {m_SE:.3f}')
```

```
Детерминация: 0.930
Скорректированная детерминация: 0.929
Стандартная ошибка: 0.065
```

Для модели множественной линейной регрессии получилось весьма большое значение скорректированного коэффициента детерминации. Оно больше, чем соответствующий коэффициент для любой из построенных ранее парных регрессий, поэтому можно предполагать, что данная модель лучше их.

Сравнить результаты парной и множественной регрессии.

	Детерминация	Скорректированная детерминация	Стандартная ошибка
Парная регрессия sl	0.612	0.612	0.052

	Детерминация	Скорректированная детерминация	Стандартная ошибка
Парная регрессия sw	0.182	0.182	0.029
Парная регрессия pl	0.901	0.901	0.063
Парная регрессия pw	0.915	0.915	0.064
Множественная регрессия	0.930	0.929	0.065

Исходя из скорректированного коэфициента детерминации, можно считать адекватными последние 3 модели. Самая большая детерминация у модели, построенной на множественной линейной регрессии, поэтому можно считать, что она является наиболее адекватной.

3. Проверить гипотезу о нормальном распределении остатков. Рассчитать статистику Дурбина-Уотсона

Проверим гипотезу о нормальности распределения остатков с помощью критерия Колмогорова-Смирнова. Также построим QQ графики для наглядности.

In [ ]:

```
import statsmodels.api as sm

pred = dict()
for column in iris_pd.columns[:-1]:
    pred[column] = reg[column].predict(iris_pd[column].values.reshape(-1, 1))

pred['multiple'] = reg['multiple'].predict(iris_m_x)

residues = dict()
for column in pred.keys():
    y_pred = pred[column]
    residues[column] = (iris_y - y_pred).reshape(-1)

    sm.qqplot(residues[column], line='45')
    ks_res = scipy.stats.kstest(residues[column], 'norm')
    plt.title(f'QQ график для {column}. \nТест Колмогорова-Смирнова - статистика
    plt.show()
```

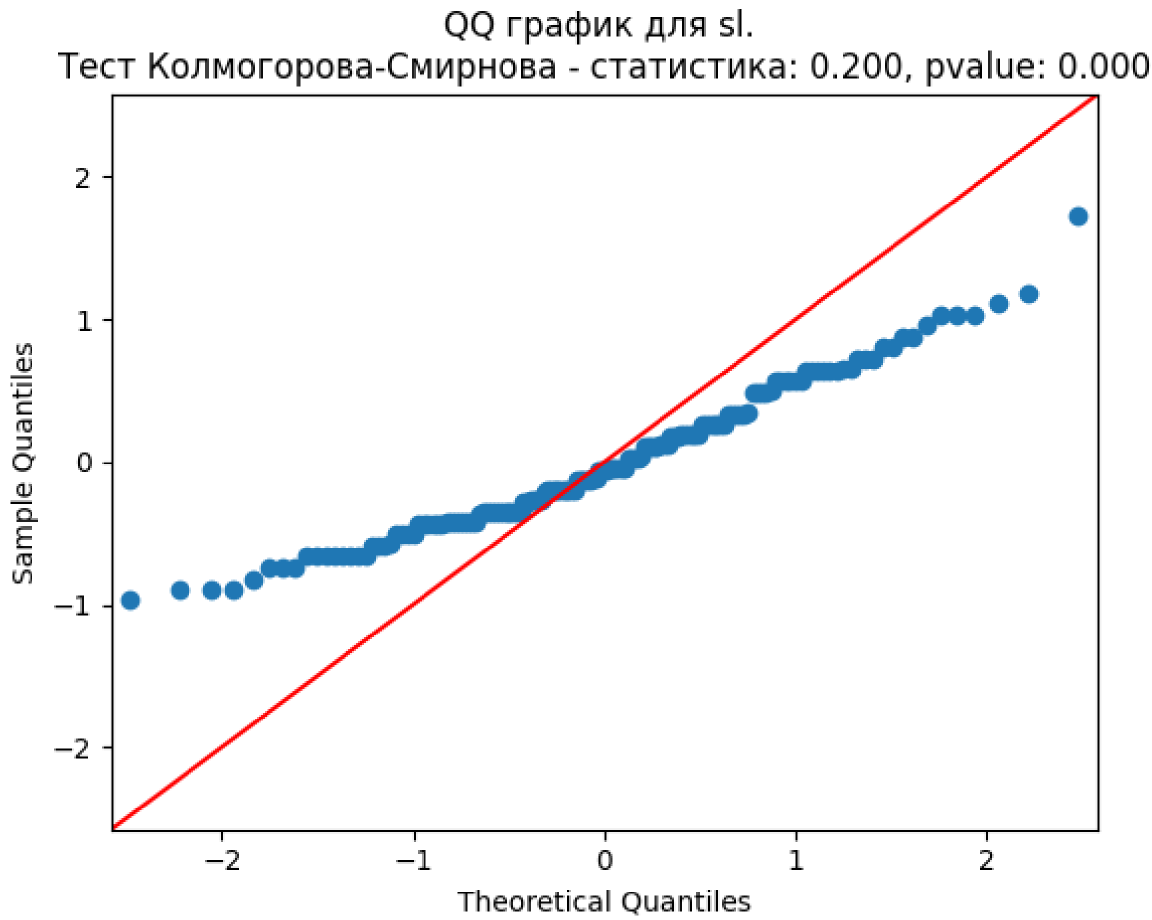
QQ график для sl.
Тест Колмогорова-Смирнова - статистика: 0.200, pvalue: 0.000
Sample Quantiles
Theoretical Quantiles
2
1
0
−1
−2

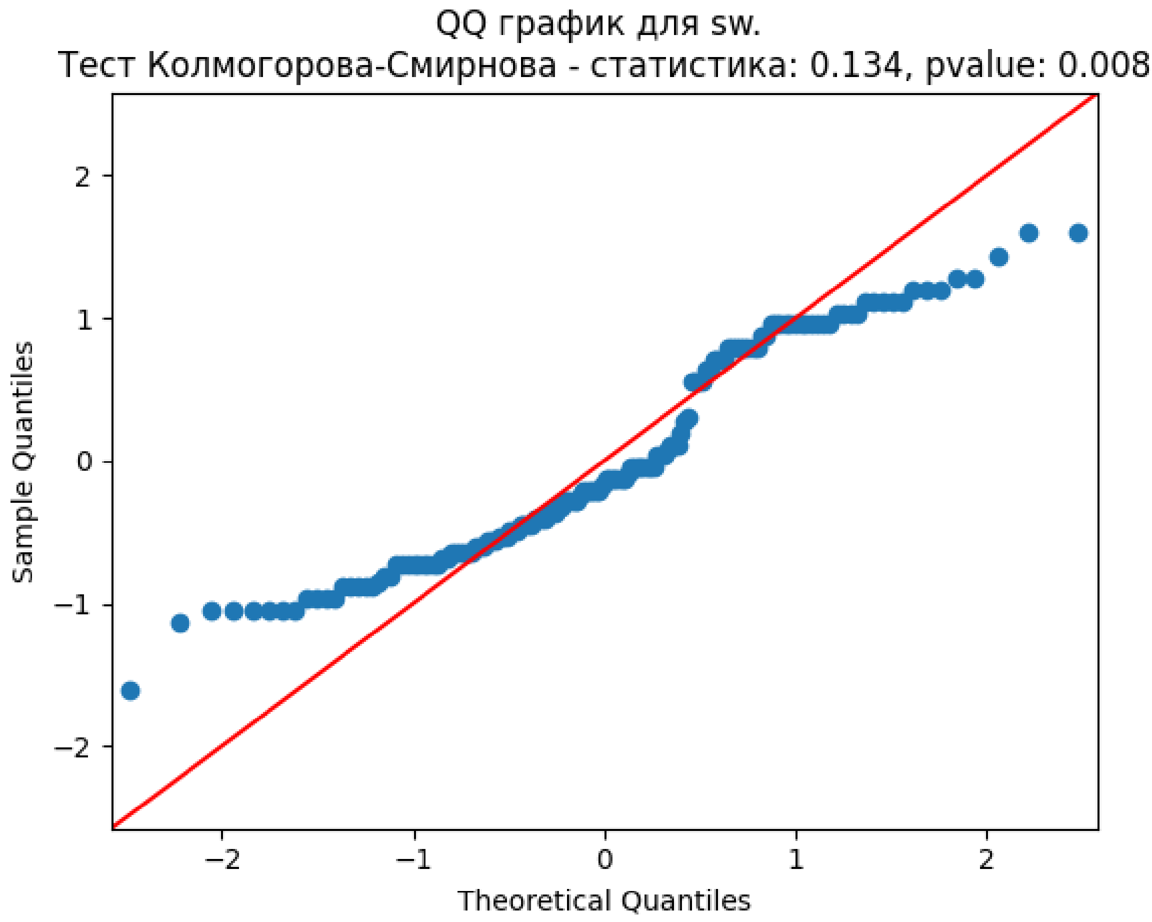
QQ график для sw.
Тест Колмогорова-Смирнова - статистика: 0.134, pvalue: 0.008
Sample Quantiles
Theoretical Quantiles
2
1
0
−1
−2

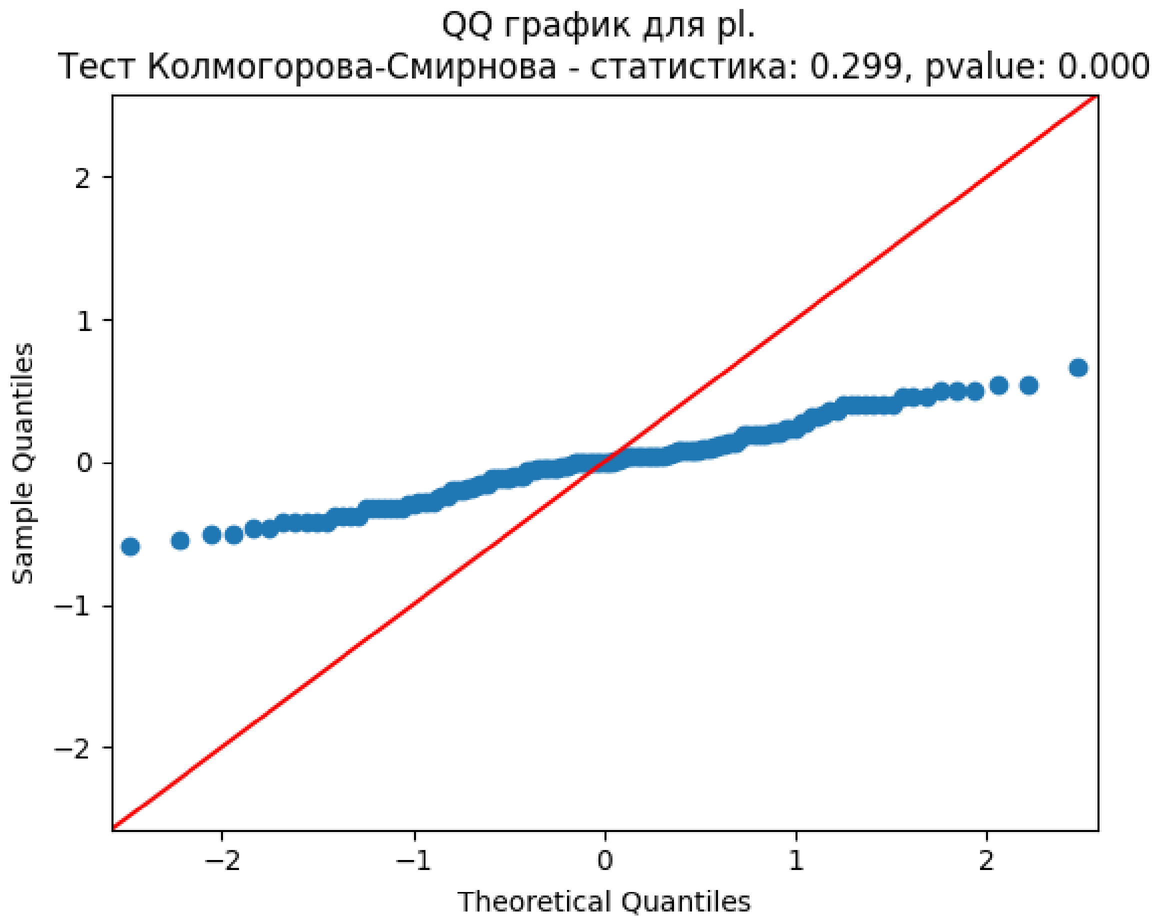

QQ график для pl.
Тест Колмогорова-Смирнова - статистика: 0.299, pvalue: 0.000
Sample Quantiles
Theoretical Quantiles

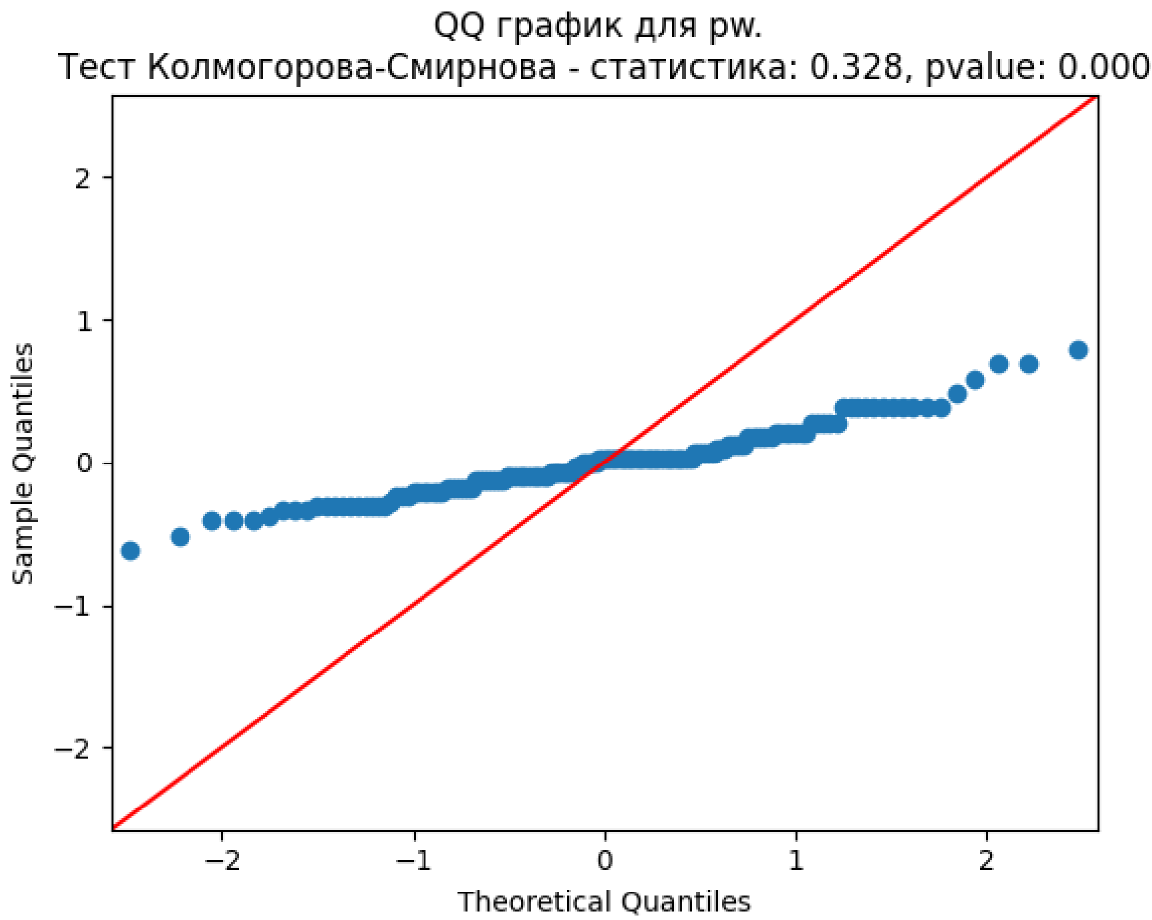

QQ график для pw.
Тест Колмогорова-Смирнова - статистика: 0.328, pvalue: 0.000
Sample Quantiles
Theoretical Quantiles

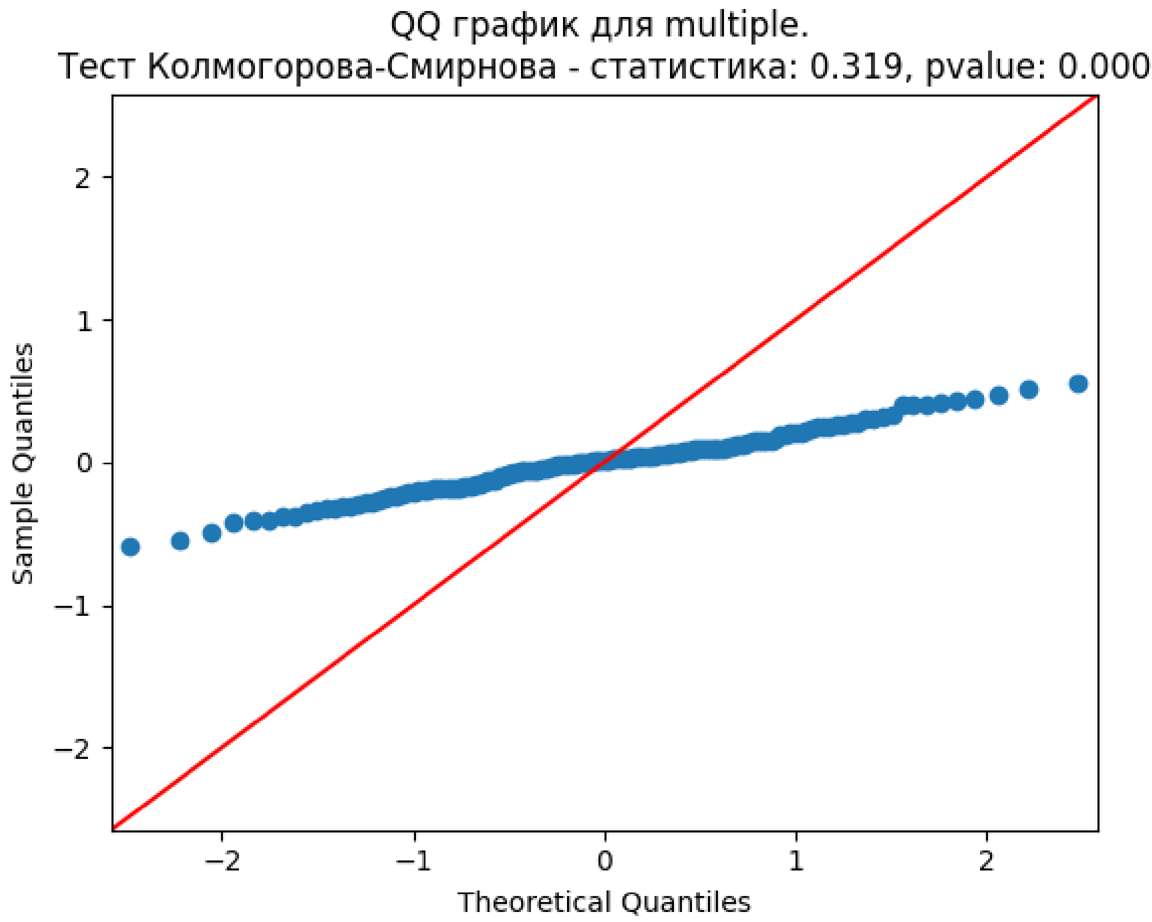

Проверим гипотезу об отсутствии автокорреляции помехи ε по критерию Дарбина-Уотсона. В нём качестве статистики используется:

$$\gamma = \frac{\sum_{i=2}^{N}(\varepsilon_i - \varepsilon_{i-1})}{Q_{\text{общ}}} \approx 2(1-\rho) \in (0, 4)$$

Зона допустимых и критических значений разделяется двумя симметричными относительно центра области определения статистики интервалами. В них критерий не даёт информации об автокорреляции. Если значение статистики находится между этими интервалами недопустимости, то выборка не противоречит гипотезе об отсутствии автокорреляции помехи. Если значение статистики находится на краях интервала $(0, 4)$, то следует отвергнуть гипотезу об отсутствии автокорреляции.

In [ ]:
```
def DW(res, Qres):
    result = 0
    for i in range(len(res)-1):
        result += (res[i+1]-res[i]) ** 2
    return result/Qres

DW_val = dict()
for column in residues:
    if column != 'multiple':
        S_res = Q_res[column]/(n-1)
    else:
        S_res = Q_res[column]/(n-k)

    DW_val[column] = DW(residues[column], Q_res[column])
```

```
print('Значение статистики Дарбина-Уотсона')
print_num_dict(DW_val, 3)
print(f'Области неопределённости теста: m = 1: (1.720, 1.746) | ({4-1.746:.3f},
print(f'\t\t\t\tm = 4: (1.679, 1.788) | ({4-1.788:.3f}, {4-1.679:.3f})')
```

```
Значение статистики Дарбина-Уотсона
sl: 1.228        sw: 0.282        pl: 1.073        pw: 1.510        multiple: 1.077
Области неопределённости теста: m = 1: (1.720, 1.746) | (2.254, 2.280)
                                m = 4: (1.679, 1.788) | (2.212, 2.321)
```

Как можем видеть, все значения статистик Дарбина-Уотсона оказались левее всех интервалов неопределённости. Таким образом гипотезу об отсутствии автокорреляции помехи следует отвергнуть для всех моделей, при чём автокорреляция положительная.

4. Проанализировать наличие выбросов. Сделать вывод о наличии (отсутствии) выбросов (с учетом результатов, полученных в предыдущих пунктах).

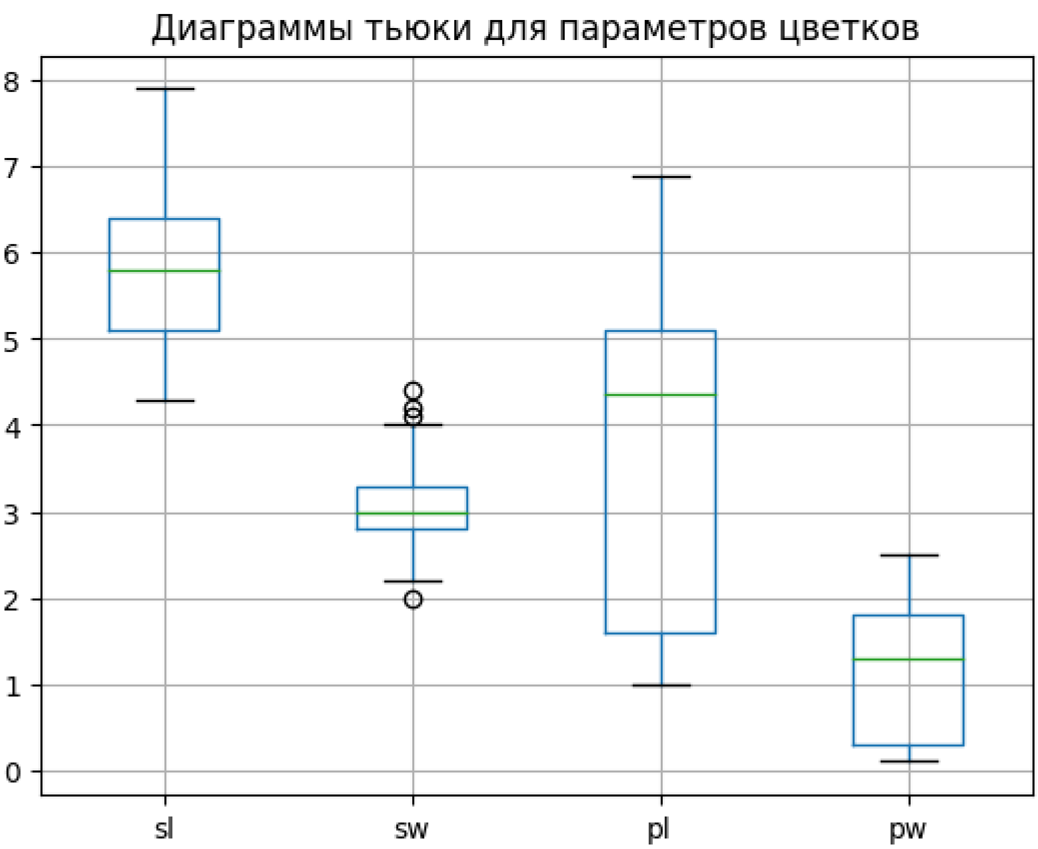

При рассмотрении диаграммы Тьюки для входных параметров, видно, что для параметра *sw* имеем большое количество выбросов и длинные усы. При построении линейной регрессии по этому параметру, мы получили очень плохую модель, имеющую детерминацию $R^2 = 0.182$. Можно предположить, что большое количество выбросов плохо влияет на получаемую модель линейной регрессии.

Сравнивая оставшиеся модели, видно, что для *sl* длина усов в отношении к самому ящику больше, чем для *pl* и *pw*. Здесь можно предположить, что модели, построенные по параметрам, имеющим "длинноусые" диаграммы Тьюки, хуже, чем по параметрам имеющим "короткоусые" диаграммы Тьюки.

5. Провести предсказание зависимой переменной по вычисленному уравнению множественной регрессии (Predict Dependent Variable), оценить точность. Для этого делим выборку на тестовую и обучающую. После чего рассчитываем СКО, коэффициент детерминации и строим график ошибок.

In [ ]:

```
from sklearn.model_selection import train_test_split

train, test = train_test_split(iris_pd, test_size=0.4)

column_train = ['sl', 'sw', 'pl', 'pw']
k_reg = len(column_train)
test_y = test['target'].values.reshape(-1, 1)
train_y = train['target'].values.reshape(-1, 1)
train_x = train[column_train].values.reshape(-1, k_reg)
test_x = test[column_train].values.reshape(-1, k_reg)

regr = linear_model.LinearRegression()
regr.fit(train_x, train_y)

test_pred = regr.predict(test_x)
test_residues = (test_y - test_pred).reshape(-1)
test_MAE = (test_residues **  2).mean()
test_Q = test_y.var()*len(test_y)
test_Qres = np.dot(test_residues, test_residues)
test_R_squared = 1 - (test_Qres/(n-k))/ (test_Q/(n-1))

print(f'MAE: {test_MAE:.3f}, R_squared={test_R_squared:.3f}')

plt.title(f'Остатки')
plt.plot(test_residues, 'r')
plt.xlabel('Номер предсказания')
plt.ylabel('Значение остатка')
plt.show()
```

```
MAE: 0.053, R_squared=0.925
```

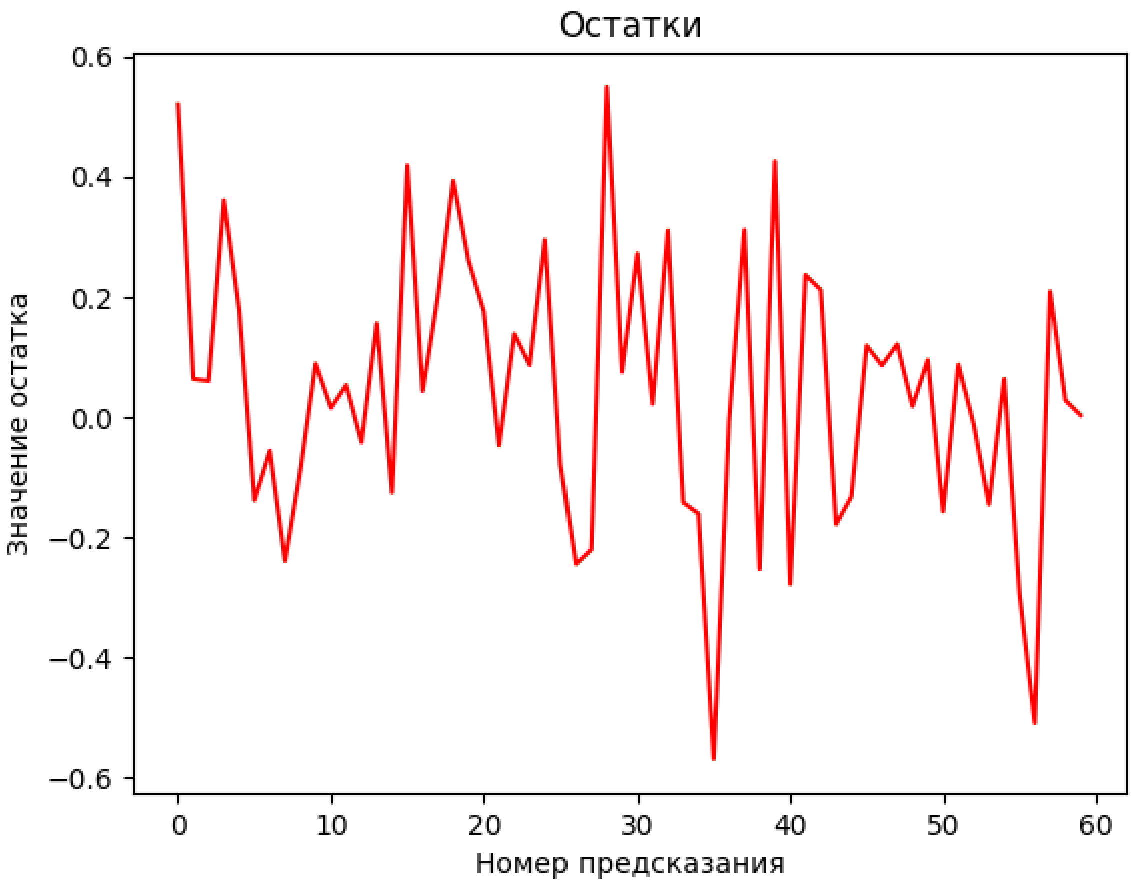

На этот раз модель оценивалась по её качеству предсказания на выборке, которая не участвовала в обучении. Судя по коэффициенту детерминации модель получилась весьма хорошей. Учитывая то, что в этот раз модель обучалась на меньшей части данных, её коэффициент детерминации практически не изменился и остался больше 0.9.

6. Сформулировать предложения по улучшению регрессионной модели.

Для улучшения модели можно сделать следующие вещи:

- Провести анализ выбросов параметра *sw*. Модель парной регрессии построенная по нему получилась плохой, возможно он оказывает не лучшее влияние на множественную регрессию;
- Можно попробовать увеличить обучающую выборку.

Датасет Бейсбол

Подготовка датасета

Обозначим роли следующими метками: Pitcher - 1, Catcher - 2, Baseman - 3, Outfielder - 4, Relief_P - 5

In [ ]:
```
import numpy  as np
import pandas as pd

data_pd=pd.read_csv('Baseball_formatted.csv', sep=';', decimal=',')

print(data_pd)
print(data_pd.describe())
```

```
     Position  Weight  Height    Age
0           2      74     180  22.99
1           2      74     215  34.69
2           2      72     210  30.78
3           3      72     210  35.43
4           3      73     188  35.71
..        ...     ...     ...    ...
110         4      76     192  25.37
111         4      74     235  29.57
112         4      72     185  27.33
113         3      72     194  26.26
114         3      74     220  27.56

[115 rows x 4 columns]
         Position      Weight      Height         Age
count  115.000000  115.000000  115.000000  115.000000
mean     3.200000   73.895652  204.191304   28.552174
std      1.440029    2.157703   20.234977    4.128190
min      1.000000   68.000000  160.000000   22.020000
25%      2.000000   73.000000  188.000000   25.110000
50%      3.000000   74.000000  205.000000   27.940000
75%      4.000000   75.000000  220.000000   31.475000
max      5.000000   81.000000  270.000000   37.740000
```

Разведочный анализ данных

In [ ]:
```
import matplotlib.pyplot as plt

data_columns = tuple(data_pd.columns)
print(data_columns)

for i in range(len(data_pd.iloc[0]) - 1):
    plt.figure(figsize=(4.0,3))
    plt.title(f'Диаграмма тьюки для {data_columns[i+1]}')
    data_pd[[data_columns[i+1]]].boxplot()
    plt.show()

plt.show()
```

```
('Position', 'Weight', 'Height', 'Age')
```

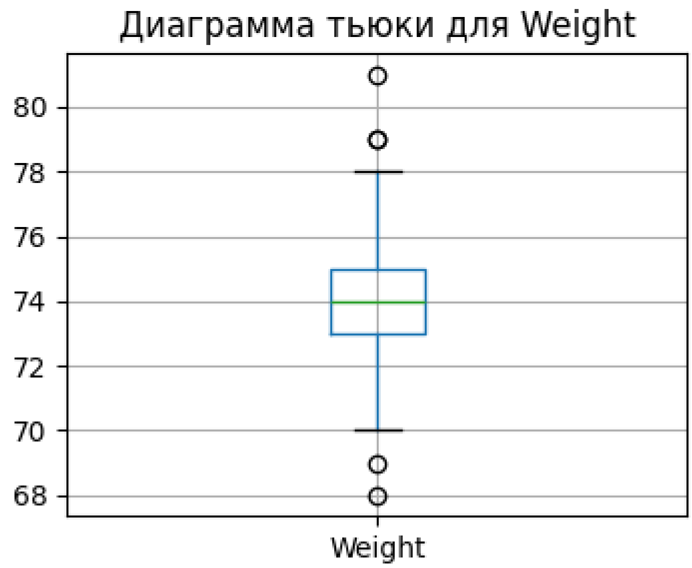

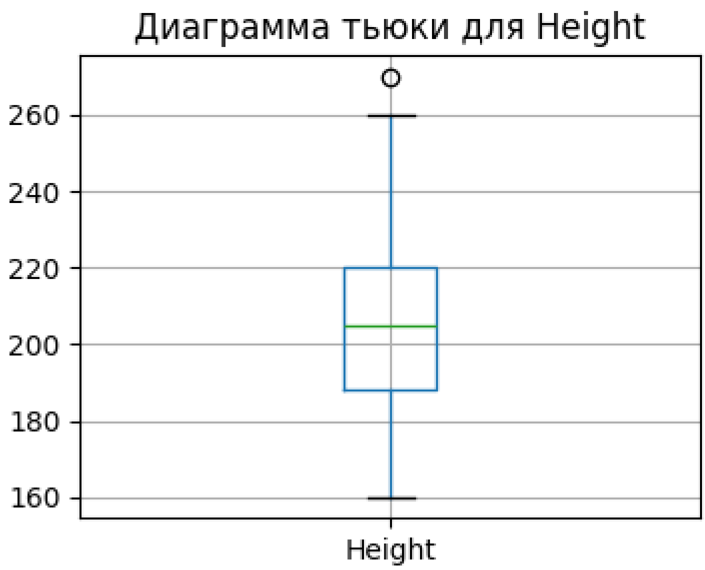

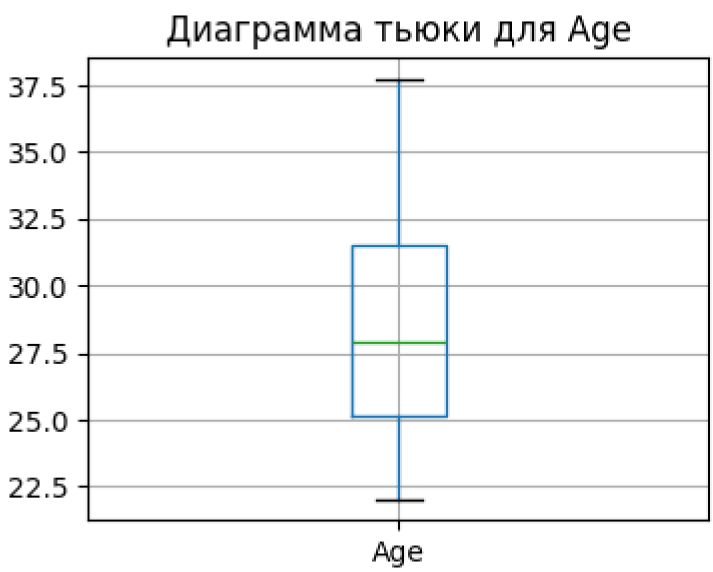

Диаграммы Тьюки для веса и роста имеют длинные усы. Также имеются выбросы. Для возраста диаграмма имеет усы не такие длинные.

In [ ]:
```
import seaborn as sns

corr_matr = data_pd.corr()
print(corr_matr)

sns.heatmap(corr_matr, annot= True, vmin=-1, vmax=1)
plt.title('Тепловая карта парных корреляций')
plt.show()
```

```
          Position    Weight    Height       Age
Position  1.000000 -0.058157 -0.152747 -0.018371
Weight   -0.058157  1.000000  0.445074 -0.082647
Height   -0.152747  0.445074  1.000000  0.277046
Age      -0.018371 -0.082647  0.277046  1.000000
```

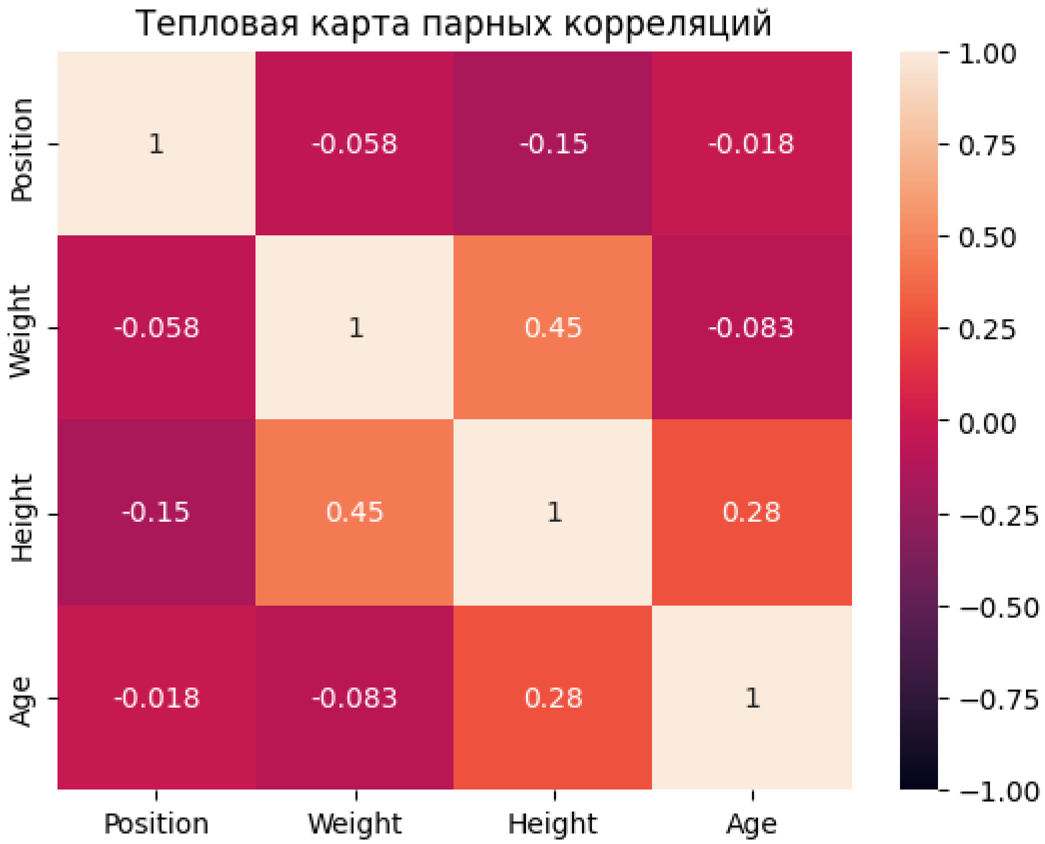

По парным корреляциям видно, что вес коррелирует с ростом, и рост коррелирует с возрастом. Это правда и это очевидно. Однако, можно заметить, что значение позиции имеет малую корреляцию с данными параметрами. Это влияет на качество модели линейной регрессии, которую можно построить по ним.

In [ ]:
```
import pingouin

pcorr_matr = data_pd.pcorr()
print(pcorr_matr)

sns.heatmap(pcorr_matr, annot= True, vmin=-1, vmax=1)
plt.title('Тепловая карта частных корреляций')
plt.show()
```

```
          Position    Weight    Height       Age
Position  1.000000  0.017659 -0.142878  0.028713
Weight    0.017659  1.000000  0.486141 -0.239729
Height   -0.142878  0.486141  1.000000  0.352009
Age       0.028713 -0.239729  0.352009  1.000000
```

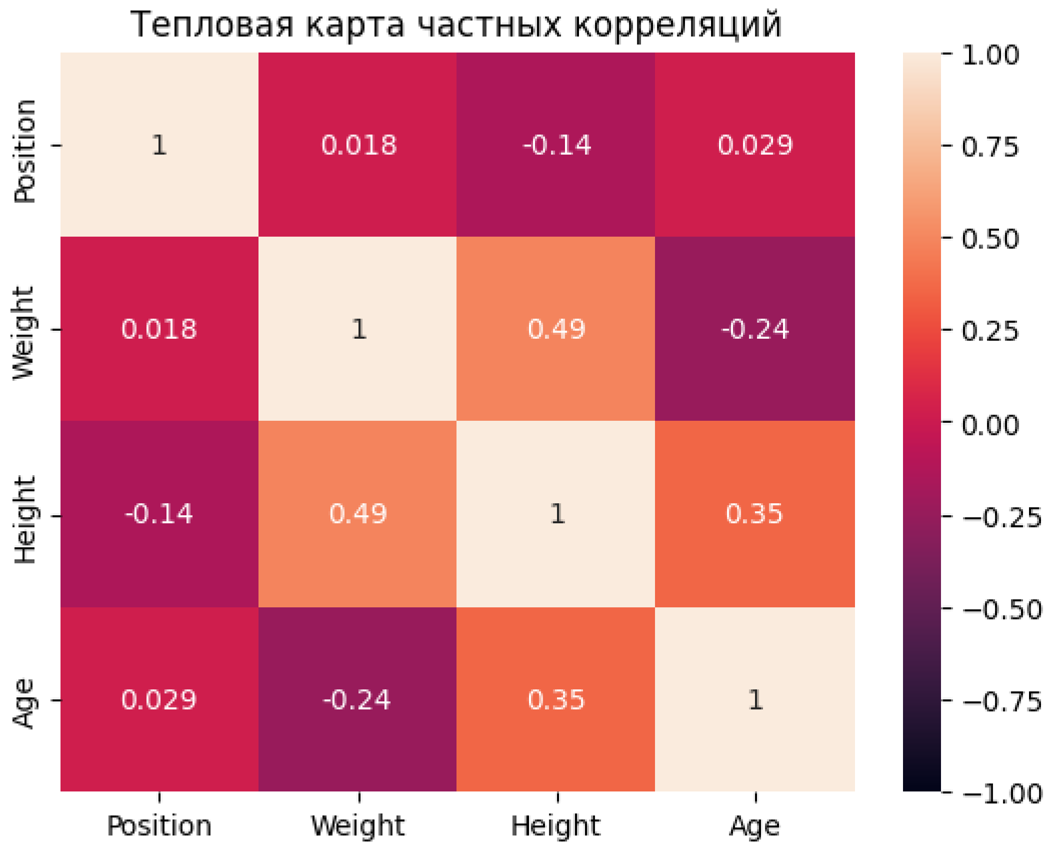


```
In [ ]:
#Количество параметров
n = len(data_pd)
k = len(data_pd.iloc[0]) - 1

def minor(A, i, j):
    a_shape = A.shape[0]
    M = np.eye(a_shape - 1)
    M[:i,:j] = A[:i,:j]
    M[:i,j:] = A[:i,j+1:]
    M[i:,:j] = A[i+1:,:j]
    M[i:,j:] = A[i+1:,j+1:]

    return M

def alg_dop(A, i, j):
    M = minor(A, i, j)
    return (-1)**(i+j) * np.linalg.det(M)

R = corr_matr.values
#Множественная корреляция y к x-ам
R_y_x = np.sqrt(1 - np.linalg.det(R)/alg_dop(R, 0, 0))
print(f'Коэффициент множественной корреляции Position: {R_y_x:.3f}')
```

```
Коэффициент множественной корреляции Position: 0.156
```

Коэффициент множественной коррреляции получился тоже малым. Это значит, что данные параметры имеют слабую линейную связь с позицией.

```
In [ ]: import scipy.stats

        kstest_res = [ scipy.stats.kstest(data_pd.iloc[:,i], 'norm') for i in range(len(
        for i in range(len(kstest_res)):
            print(f'Значение статистики для {data_columns[i]}: {kstest_res[i].statistic:
```

```
Значение статистики для Position: 0.841, pvalue: 5.51e-92
Значение статистики для Weight: 1.000, pvalue: 0.00e+00
Значение статистики для Height: 1.000, pvalue: 0.00e+00
Значение статистики для Age: 1.000, pvalue: 0.00e+00
```

Все имеющиеся параметры почти наверняка не распределены нормально.

```
In [ ]: data_pd.iloc[:,:].hist(bins = 8, edgecolor='black')
        plt.show()
```

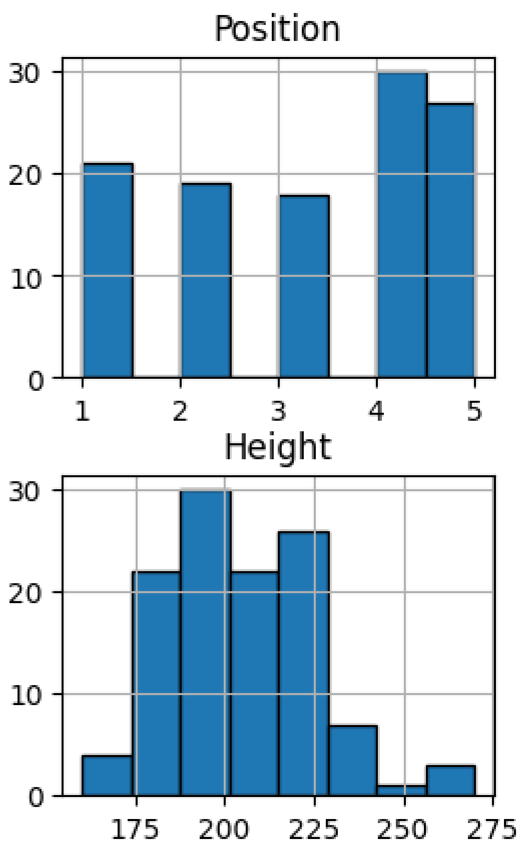

Ненормальность распределений параметров видна на данных оценках распределений.

Датасет Barotrop

Подготовка датасета

Обозначим классы следующими метками: BARO - 0, TROP - 1.

In [ ]:
```
import numpy  as np
import pandas as pd

data_pd=pd.read_csv('Barotrop_formatted.csv', sep=';', decimal=',')

print(data_pd.head(10))
print(data_pd.tail(10))
print(data_pd.describe())
```

```
   LONGITUD  LATITUDE  CLASS
0      59.0        17      0
1      59.5        21      0
2      60.0        12      0
3      60.5        16      0
4      61.0        13      0
5      61.0        15      0
6      61.5        17      0
7      61.5        19      0
8      62.0        14      0
9      63.0        15      1
    LONGITUD  LATITUDE  CLASS
27      68.0        14      0
28      68.5        18      0
29      69.0        13      0
30      69.0        15      0
31      69.5        17      0
32      69.5        19      0
33      70.0        12      0
34      70.5        16      0
35      71.0        17      0
36      71.5        21      0
        LONGITUD   LATITUDE      CLASS
count  37.000000  37.000000  37.000000
mean   65.432432  16.216216   0.486486
std     3.438269   2.709399   0.506712
min    59.000000  12.000000   0.000000
25%    63.000000  14.000000   0.000000
50%    65.500000  16.000000   0.000000
75%    68.000000  18.000000   1.000000
max    71.500000  21.000000   1.000000
```

Разведочный анализ данных

In [ ]:
```
import matplotlib.pyplot as plt

data_columns = tuple(data_pd.columns)

for i in range(len(data_pd.iloc[0]) - 1):
```

```
    plt.figure(figsize=(4.0,3))
    plt.title(f'Диаграмма тьюки для {data_columns[i]}')
    data_pd[[data_columns[i]]].boxplot()
    plt.show()

plt.show()
```

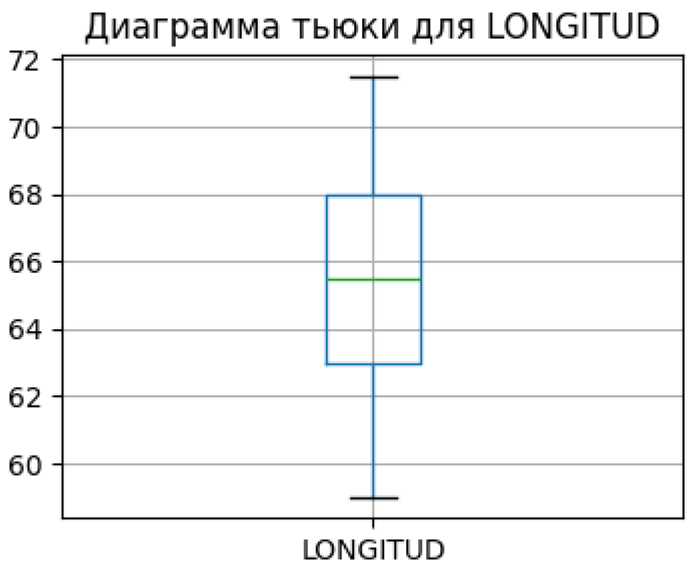

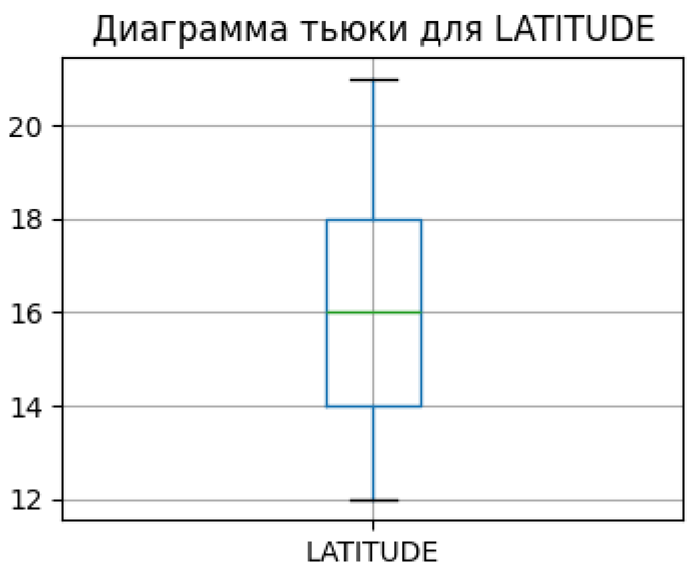

Димаграммы Тьюки выглядят симметричными, а медиана находится ровно в середине ящика. Вполне возможно, что данные параметры распределены нормально. Также выбросы не наблюдаются, а усы не выглядят большими.

In [ ]:
```
import seaborn as sns

corr_matr = data_pd.corr()
print(corr_matr)

sns.heatmap(corr_matr, annot= True, vmin=-1, vmax=1)
plt.title('Тепловая карта парных корреляций')
plt.show()
```

```
          LONGITUD  LATITUDE     CLASS
LONGITUD  1.000000  0.080631  0.011419
LATITUDE  0.080631  1.000000  0.042654
CLASS     0.011419  0.042654  1.000000
```

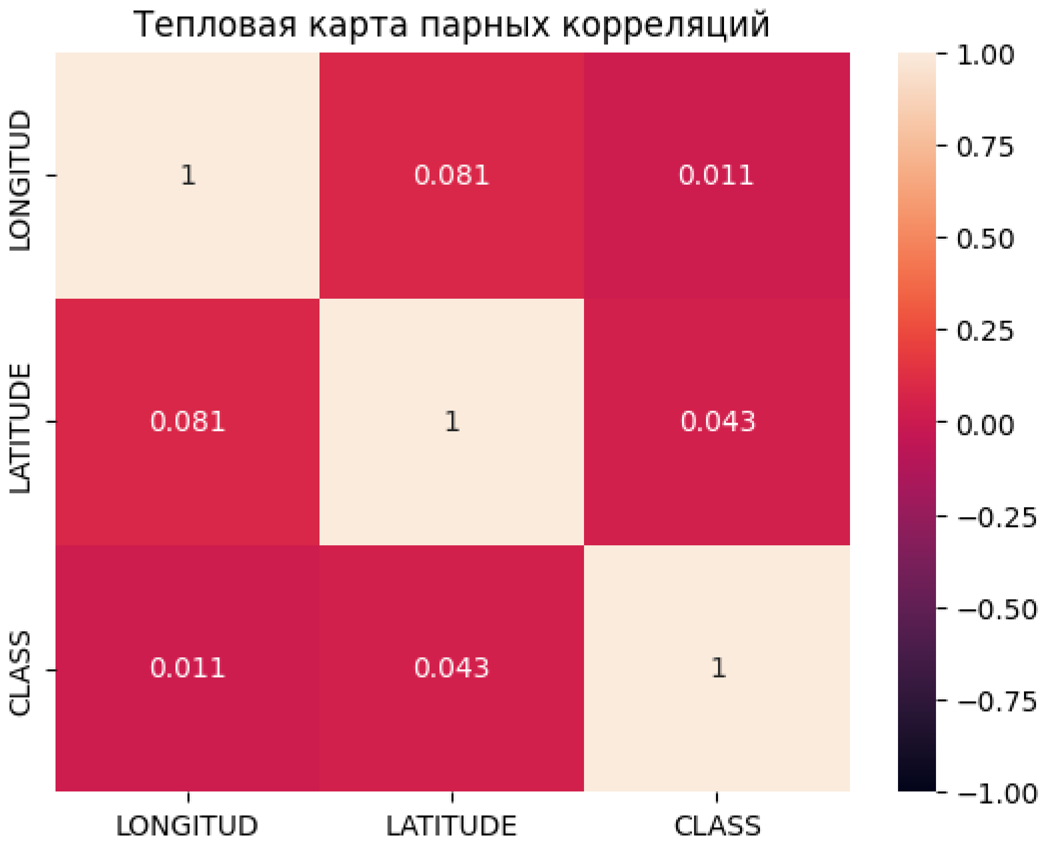

Судя по парным корреляциям, между всеми переменными корреляции не наблюдаются.

In [ ]:
```python
import pingouin

pcorr_matr = data_pd.pcorr()
print(pcorr_matr)

sns.heatmap(pcorr_matr, annot= True, vmin=-1, vmax=1)
plt.title('Тепловая карта частных корреляций')
plt.show()
```

```
          LONGITUD  LATITUDE     CLASS
LONGITUD  1.000000  0.080222  0.008014
LATITUDE  0.080222  1.000000  0.041872
CLASS     0.008014  0.041872  1.000000
```

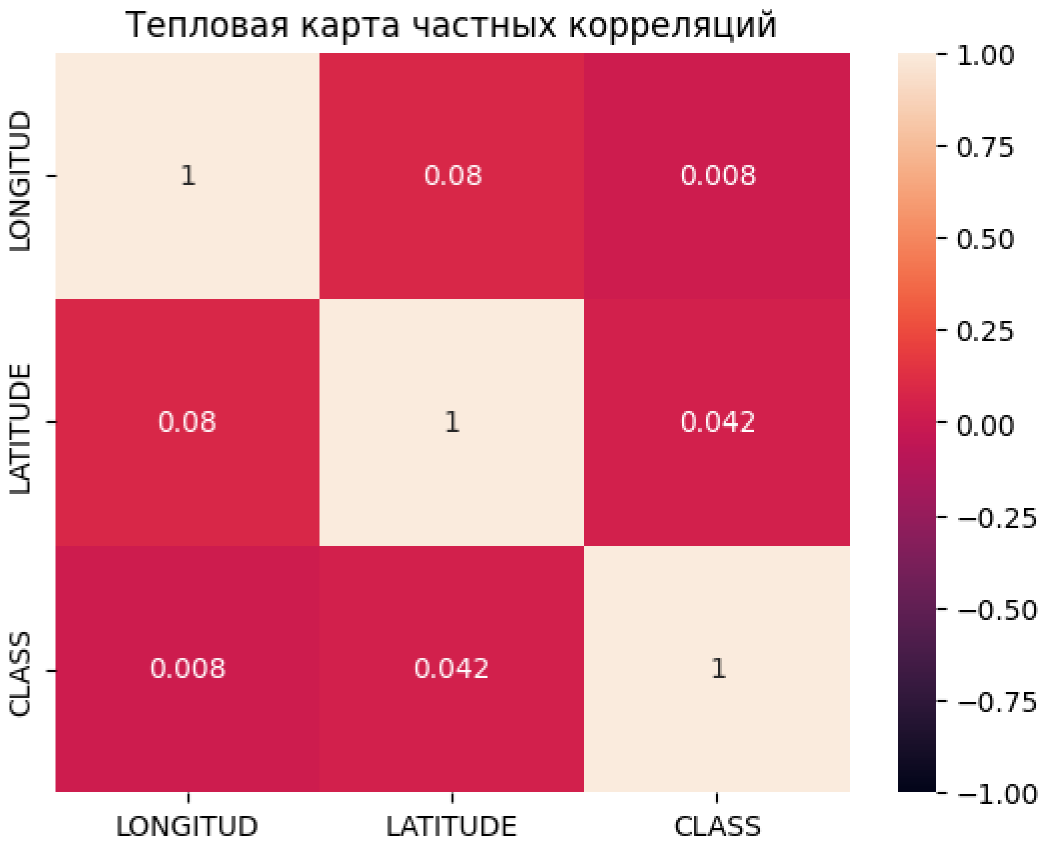

In [ ]:

```
#Количество параметров
n = len(data_pd)
k = len(data_pd.iloc[0]) - 1

def minor(A, i, j):
    a_shape = A.shape[0]
    M = np.eye(a_shape - 1)
    M[:i,:j] = A[:i,:j]
    M[:i,j:] = A[:i,j+1:]
    M[i:,:j] = A[i+1:,:j]
    M[i:,j:] = A[i+1:,j+1:]

    return M

def alg_dop(A, i, j):
    M = minor(A, i, j)
    return (-1)**(i+j) * np.linalg.det(M)

R = corr_matr.values
#Множественная корреляция y к x-ам
R_y_x = np.sqrt(1 - np.linalg.det(R)/alg_dop(R, k, k))
print(f'Коэффициент множественной корреляции Position: {R_y_x:.3f}')
```

```
Коэффициент множественной корреляции Position: 0.043
```

Коэффициент множественной коррреляции получился тоже малым. Это значит, что данные параметры имеют слабую линейную связь с классом.

In [ ]:

```
import scipy.stats

kstest_res = [ scipy.stats.kstest(data_pd.iloc[:,i], 'norm') for i in range(len(
for i in range(len(kstest_res)):
    print(f'Значение статистики для {data_columns[i]}: {kstest_res[i].statistic:
```

```
Значение статистики для LONGITUD: 1.000, pvalue: 0.00e+00
Значение статистики для LATITUDE: 1.000, pvalue: 0.00e+00
Значение статистики для CLASS: 0.500, pvalue: 4.45e-09
```

Все имеющиеся параметры почти наверняка не распределены нормально.

In [ ]:
```
data_pd.iloc[:,:].hist(bins = 8, edgecolor='black')
plt.show()
```

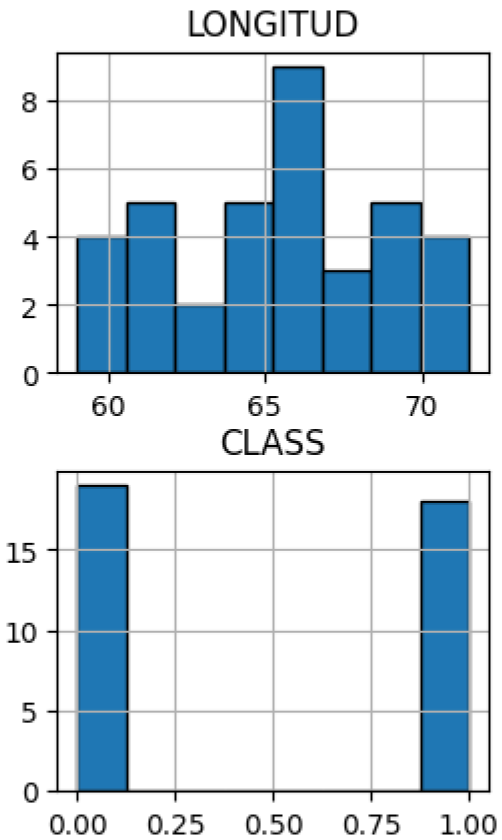

Ненормальность распределений параметров видна на данных оценках распределений.

В данном датасете корреляция между параметрами не наблюдается. Это значит, что скорее всего модели основанные на линейной регрессии будут неэффективны, и строить их здесь не целесообразно.